

Universidad Rafael Landívar  
Ciencia de Datos  
Segundo Semestre 2026  
Ing. Max Cerna

## Agencia Metropolitana de Transporte

| Modalidad          | Ponderación | Fases                                | Defensa           |
|--------------------|-------------|--------------------------------------|-------------------|
| Grupos de 3/ max 4 | 100 puntos  | Fase 1 arquitectura / Fase 2 tablero | Oral, obligatoria |

### Contexto

El congestionamiento vehicular en el área metropolitana de Guatemala cuesta alrededor de Q25 mil millones anuales (cerca del 9.4% del PIB departamental) y una pérdida aproximada de Q1,300 mensuales por trabajador. En la capital se pierden en promedio cuatro horas diarias en el tráfico, hasta seis para quienes viajan desde municipios aledaños. Emetra proyecta que el departamento podría cerrar en 2026 con 3 millones de vehículos.

La ciudad tiene hoy dos sistemas de transporte masivo operando (Transmetro y Transurbano) y dos propuestas una en construcción y la otra en planificación: el Aerómetro y el MetroRiel, un tren ligero de 21 km y 22 estaciones que conectará Centra Sur con Centra Norte atravesando las zonas 12, 8, 1, 6 y 17.

El diagnóstico institucional es conocido, actualmente no existe una Agencia Metropolitana de Transporte. La Municipalidad, CIV y FEGUA operan por separado, con presupuestos, estándares y sistemas distintos. Y mientras tanto, el estudio de demanda de pasajeros del MetroRiel sigue abierto.

#### Ustedes son el equipo de datos de esa nueva Agencia que todavía no existe

Su trabajo no es construir trenes. Es construir la capacidad de responder, con evidencia, si la red integrada resuelve el problema y dónde no.

### El problema técnico

Los cuatro operadores registran sus viajes, y ninguno lo hace igual:


|                         | Transmetro          | Transurbano                     | MetroRiel         | Aerometro                 |
|-------------------------|---------------------|---------------------------------|-------------------|---------------------------|
| <b>Formato</b>          | CSV                 | CSV                             | JSON Lines        | CSV                       |
| <b>Una fila es</b>      | un abordaje         | una transacción                 | un viaje completo | un abordaje               |
| <b>Llave de usuario</b> | TC-00012345         | 0000012345                      | MR0012345         | hash de 12 c.             |
| <b>Fecha</b>            | YYYY-MM-DD HH:MM:SS | fecha y hora en cols. separadas | ISO 8601          | ISO en UTC, no hora local |
| <b>Dinero</b>           | quetzales           | centavos                        | quetzales         | quetzales                 |
| <b>Zona</b>             | Zona 10             | Z10 mayúsculas                  | Zona 10           | district, en inglés       |

Además reciben un archivo de CDC del padrón de usuarios con operaciones INSERT, UPDATE y DELETE. Los borrados llegan con la llave y sin cuerpo.

**Ningún archivo se puede unir con otro tal como está. Ese es el trabajo.**

## Arquitectura Esperada

Esto es lo que se espera construir:



### Consideraciones: lo que este diagrama exige aplicar y se evaluará

Gold NUNCA lee la capa de Bronze directamente, siempre el dato pasa por Silver.

Los malos registros van a cuarentena, no se descartan.

El staging se vacía, mientras la capa Bronze se acumula.

Las features de ML salen de Silver, no de Gold: Gold ya agregó a un grano de negocio que el modelo no necesita.

## Datos Generados

Se les proveerá un archivo `generar_red_metropolitana.py` el cual deben ejecutar y generará nueve archivos en el directorio `/datos_red/`:

| Archivo                                    | Tipo                                  |
|--------------------------------------------|---------------------------------------|
| <code>tm_estaciones.csv</code>             | catálogo con 8 líneas de transmetro   |
| <code>tu_paradas.csv</code>                | catálogo con 41 rutas de transurbano  |
| <code>mr_estaciones.csv</code>             | catálogo con 22 estaciones metro riel |
| <code>am_estaciones.csv</code>             | catálogo con 2 ejes de aero metro     |
| <code>transmetro_validaciones.csv</code>   | operación                             |
| <code>transurbano_transacciones.csv</code> | operación                             |
| <code>metroriel_viajes.jsonl</code>        | operación                             |
| <code>aerometro_boardings.csv</code>       | operación                             |
| <code>cdc_padron_usuarios.csv</code>       | cambios en el padrón (Transmetro)     |

Con la configuración por defecto son unos 200 MB. La variable `ESCALA` controla el volumen: con 1.0 se generan unas cifras aproximadas al tamaño de la ciudad (~2.5 GB), y no sería necesario llegar hasta ahí.

Los datos son generados, pero calibrados con cifras públicas: 8 líneas y frecuencia de 5 minutos en Transmetro, 41 rutas y 270,000 pasajeros diarios en Transurbano, 22 estaciones y 41 minutos de recorrido en MetroRiel.

## FASE 1 – Desglose de la arquitectura (49 puntos)

### 1.1 Ingesta y capa Bronze (8 pts)

Las tres vías de ingesta no son intercambiables. Cada fuente entra por la que le corresponde, y esa decisión se justifica:

| Vía                      | Qué ingresa por aquí                                                    | Por qué                                                                                          |
|--------------------------|-------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| <b>Streaming (Kafka)</b> | Las validaciones de Transmetro y los boardings de Aerómetro             | Son eventos que en producción llegan continuamente. Se simulan publicando el CSV línea por línea |
| <b>Batch</b>             | Los cuatro catálogos de estaciones y paradas, y los viajes de MetroRiel | Los catálogos cambian rara vez. MetroRiel entrega el viaje ya cerrado, no evento por evento      |
| <b>CDC</b>               | El padrón de usuarios                                                   | Es lo único que se actualiza y se borra. Los demás archivos solo crecen                          |

Transurbano queda a su criterio. Argumenten por cuál vía lo ingieren y qué consecuencia tiene esa decisión.

Bronze conserva el dato tal como llegó, con marca de tiempo de ingesta y particionado por fecha.

Decidan y justifiquen si la capa Bronze vive en un lake o en el warehouse, considerando que uno de los archivos es JSON anidado.

**Entregable:** scripts de carga por vía, tabla de conteos por archivo, y la justificación de la vía elegida para Transurbano.

### 1.2 Staging y CDC (9 pts)

Procesen el archivo [cdc\\_padron\\_usuarios.csv](#) para construir el padrón vigente de Transmetro.

Apliquen las tres operaciones en orden de secuencia

Los DELETED deben marcar la tarjeta como inactiva, no borrarla. Si la borran, se perdería el historial de sus viajes

Documenten cuántas tarjetas quedaron activas y cuántas dadas de baja

Para Transurbano, MetroRiel y Aerómetro no existe un padrón. Construyan un catálogo mínimo de usuarios para cada uno, extrayendo las llaves distintas que aparecen en sus archivos de operación (transurbano\_transacciones.csv, metroriel\_viajes.jsonl, aerometro\_boardings.csv). Estos catálogos sólo van a tener la llave, sin nombre, sin fecha de alta, sin ningún atributo, porque esos operadores nunca entregaron esa información. No inventen datos que no existen.

**Entregable:** el modelo de CDC de Transmetro con el conteo antes/después de aplicar los borrados, y el catálogo de llaves distintas construido para cada uno de los otros tres operadores, con el conteo de usuarios únicos encontrados.

### 1.3 Capa Silver (12 pts)

Aquí se resuelve el problema de integración:

- Unificar formatos: fechas a un solo estándar, montos a quetzales, Aerómetro de UTC a hora local
- Conformar la dimensión zona: Z10, Zona 10 y district deben apuntar a la misma zona
- Resolver la identidad del usuario: los cuatro sistemas usan llaves distintas. Propongan y justifiquen una estrategia
- Aplicar reglas de calidad: hay duplicados de torniquete, códigos de parada nulos, fechas del futuro y viajes sin salida. Los registros malos van a cuarentena, no a la basura
- Historizar el padrón con SCD Tipo 2

**Entregable:** modelos de Silver, tabla de cuarentena con motivo de rechazo, y un conteo de registros por regla de calidad.

### 1.4 Diseño dimensional y capa Gold (15 pts)

- Declaren el grano de su tabla de hechos principal, en una frase. Cuidado: MetroRiel registra el trayecto completo y los otros tres registran abordajes
- Definan su Matriz del bus de los procesos que modelen
- Al menos dos tablas de hechos, con sus dimensiones conformadas (pueden ser cuantas requieran)
- Dimensión tiempo con hora del día, día hábil y hora pico
- Clasifiquen sus medidas: aditivas, semi-aditivas, no aditivas

**Entregable:** diagrama del modelo, matriz del bus, y el DDL.

### 1.5 Orquestación e idempotencia (5 pts)

El flujo completo debe poder correrse dos veces sin duplicar nada. Deben demostrarlo: corran, cuenten, vuelvan a correr, cuenten otra vez. Esto debe ser demostrado tanto durante su proceso de desarrollo como el día de la presentación.

**Entregable:** evidencia de las dos corridas con los conteos idénticos (esto corresponde al periodo de desarrollo cuando realizaron sus pruebas).

## FASE 2 – El tablero y la recomendación (33 puntos y 18 puntos de gobernanza, documentación y seguridad)

### 2.1 Tablero en Tableau (16 pts)

Conectado a la capa Gold. Debe responder al menos:

- Demanda por modo, zona y hora ¿dónde y cuándo se concentra?
- Cobertura: qué zonas quedan sin servicio de ningún modo
- Transbordo: cuántos usuarios usan más de un sistema
- El caso MetroRiel: dada la demanda observada en las zonas 12, 8, 1, 6 y 17, ¿el trazado propuesto atiende donde más se necesita?

### 2.2 La recomendación (10 pts)

Un documento de máximo dos páginas que responda:

**Con estos datos, ¿los cuatro modos integrados resuelven el problema de movilidad? ¿Dónde sí y dónde no?**

Debe incluir una recomendación concreta y defendible por ejemplo: “dónde ubicar una estación de transbordo, qué corredor sigue descubierto, qué modo está subutilizado” sostenida con cifras de su propio tablero.

No se evalúa que la recomendación sea “correcta”, se evalúa que se derive de los datos y que puedan defenderla cuando se les pregunte por qué.

### 2.3 Capa de features para ciencia de datos (7 pts)

El tablero no es el único consumidor, construyan además una tabla de features lista para entrenar un modelo, no elabore dicho modelo, solo la tabla.

**Se debe sacar de Silver, no de Gold. Gold ya definió un grano de negocio, el feature engineering necesita el detalle atómico para agregarlo a su manera.**

La entidad a predecir: un usuario. Una fila por usuario, con columnas derivadas de su historial. Por ejemplo:

- viajes en los últimos 7, 30 y 90 días
- modo más usado, cantidad de modos distintos, hace cuántos días fue el último viaje
- proporción de viajes en hora pico, zona de origen más frecuente
- gasto acumulado y promedio por viaje

**Entregable:** la tabla de features con su diccionario, la fecha de corte declarada, y una frase que explique qué se podría predecir con ella y por qué le serviría a la Agencia.

## Tecnologías: opciones y recomendación

La columna recomendada es la que en el curso será respaldada y sobre la que se le podrá dar soporte. Son libres de sustituirla, pero la sustitución hay que justificarla en la documentación.

| Pieza               | Recomendada         | Alternativas                                  | Nota                                                             |
|---------------------|---------------------|-----------------------------------------------|------------------------------------------------------------------|
| Ingesta streaming   | Kafka en Docker     | Redpanda con CSV directo                      | Se simula: un script publica el CSV línea por línea              |
| Lake / Bronze       | carpetas + Parquet  | MinIO - Delta - Iceberg                       | Una carpeta particionada por fecha ES un lake                    |
| Staging y Warehouse | PostgreSQL o DuckDB | MySQL - SQL Server - SQLite                   | DuckDB si quieren cero configuración                             |
| Transformación      | dbt                 | SQL puro - Spark SQL                          | Obligatorio. Da pruebas y linaje sin esfuerzo                    |
| CDC                 | procesar el archivo | más avanzado: Debezium con replicación lógica | El archivo ya viene en formato de log                            |
| Orquestación        | Prefect             | Airflow - Dagster - cron                      | Prefect levanta sin servidor, Airflow es el estándar del mercado |
| Visualización       | Tableau             | —                                             | Obligatorio como se mencionó en el programa                      |

## Métricas que deben reportar

El proyecto no se evalúa solo por funcionar. Reporten estas cifras en la documentación, medidas por ustedes:

| Categoría    | Qué medir                                                                           |
|--------------|-------------------------------------------------------------------------------------|
| Volumen      | Filas ingeridas por fuente, filas que llegaron a Silver, filas en Gold              |
| Calidad      | Registros en cuarentena por motivo, porcentaje del total, duplicados detectados     |
| CDC          | Altas, cambios y bajas aplicadas, tarjetas activas antes y después                  |
| Rendimiento  | Duración de cada etapa, tamaño en disco por capa, tiempo de la consulta del tablero |
| Idempotencia | Conteos de la primera y la segunda corrida (deben ser idénticos)                    |
| Cobertura    | Zonas con servicio y sin servicio (usuarios que usan más de un modo)                |

Una comparación sin números medidos no cuenta: es una suposición, no un resultado.

### 3.1 Gobernanza de datos (8 pts)

Los cuatro operadores van a compartir un warehouse. Sin reglas explícitas, cada uno seguirá midiendo a su manera y el problema no se va a resolver tal como se vio en clase, entonces deben definir su gobernaza.

| Instrumento            | Qué debe contener                                                                                                                           |
|------------------------|---------------------------------------------------------------------------------------------------------------------------------------------|
| Diccionario de datos   | <u>Para cada campo de Gold:</u> qué significa, de qué fuente sale, qué transformación se le aplicó                                          |
| Definiciones oficiales | ¿Qué cuenta como “un viaje”? ¿Y como “un usuario activo”? Los cuatro operadores lo definen distinto, ustedes deciden y lo dejan por escrito |
| Dueño por dominio      | Quién responde por cada dimensión conformada. Si mañana cambia la definición de zona, ¿quién autoriza?                                      |
| Linaje                 | De cada métrica del tablero se debe poder llegar hasta el archivo crudo. dbt lo genera solo, inclúyanlo                                     |
| Reglas de calidad      | Qué se considera un registro inválido, y qué se hace con él. Documentado antes de escribir el código                                        |

La que podrían considerar como una prueba de fuego para validar su gobernanza, si dos integrantes del grupo calculan "viajes del mes" por separado, ¿obtienen el mismo número? Si no, la gobernanza está incompleta.

**Entregable:** diccionario de datos de Gold, documento de definiciones oficiales con dueño asignado, y el grafo de linaje de dbt.

### 3.2 Documentación y reproducibilidad (5 pts)

- README con requisitos, pasos de instalación y cómo correr el flujo completo
- Decisiones de diseño: el grano y por qué, la estrategia de identidad del usuario y sus límites, qué se mandó a cuarentena y con qué criterio
- Repositorio en Git con historial real de commits, no una sola subida final

**Entregable:** repositorio con README y bitácora de decisiones.

### 3.3 Seguridad y manejo de datos personales (5 pts)

Los datos son generados, pero el escenario no: un sistema real de transporte sabe dónde estuvo cada persona, a qué hora, todos los días. Eso es información sensible.

- Nada de credenciales en el repositorio. Usen variables de entorno o un archivo de ejemplo sin valores reales
- Seudonimizar la llave de usuario antes de Gold: el tablero no necesita saber qué tarjeta es, solo saber que es la misma persona
- Declaren quién debería ver qué: por ejemplo, un analista no necesita el detalle por individuo, un auditor de fraude sí
- Una línea sobre retención: ¿cuánto tiempo se conserva el detalle individual, y por qué ese plazo?

**Entregable:** una página con estas cuatro decisiones y su justificación.

## Evaluación

| Componente                           | Puntos     |
|--------------------------------------|------------|
| 1.1 Ingesta por vía y Bronze         | 8          |
| 1.2 Staging y CDC                    | 9          |
| 1.3 Silver: integración y calidad    | 12         |
| 1.4 Diseño dimensional y Gold        | 15         |
| 1.5 Orquestación e idempotencia      | 5          |
| 2.1 Tablero                          | 16         |
| 2.2 Recomendación                    | 10         |
| 2.3 Capa de features                 | 7          |
| 3.1 Gobernanza de datos              | 8          |
| 3.2 Documentación y reproducibilidad | 5          |
| 3.3 Seguridad y datos personales     | 5          |
| <b>Total</b>                         | <b>100</b> |

Durante la defensa oral cada integrante debe poder explicar cualquier parte del proyecto.

## Penalizaciones

- Un modelo Gold que lea directamente de Bronze pierde la totalidad de 1.4, aunque el resultado numérico sea correcto.
- Descartar registros malos en silencio, sin cuarentena ni conteo, pierde la mitad de 1.3.
- Un flujo que no sea idempotente pierde 1.5 completo, sin crédito parcial.
- Un tablero que no se pueda rastrear hasta el dato crudo pierde la mitad de 2.1.

## Extras para enriquecer la arquitectura

**Opcionales:** No suman puntos por sí solos, pero sí pesan en la defensa oral y distinguen un proyecto que cumple de uno que se nota trabajado.

| Extra                  | Qué agrega                                                                                  |
|------------------------|---------------------------------------------------------------------------------------------|
| CDC real con Debezium  | Capturar del log de PostgreSQL en vez de leer el archivo. Es lo que se hace en la industria |
| Delta Lake o Iceberg   | Transacciones ACID y time travel sobre el lake local. Consultar cómo se veía una tabla ayer |
| Pruebas en CI          | GitHub Actions que corra dbt test en cada push. El pipeline se valida solo                  |
| Modelos incrementales  | Procesar solo lo nuevo en cada corrida, en vez de recalcular todo                           |
| Alertas de frescura    | Avisar si una fuente dejó de llegar (Monitoreo, no solo transformación)                     |
| Análisis de transbordo | Inferir viajes multimodales encadenando validaciones cercanas en tiempo y espacio           |

## Advertencias útiles

El grano es la decisión más difícil de este proyecto. MetroRiel les da el viaje completo, los otros tres, abordajes sueltos. Si eligen “un viaje puerta a puerta” como grano, tendrán que inferirlo para tres de los cuatro sistemas y esa inferencia hay que justificarla. Si eligen “un abordaje”, MetroRiel les sobra información. Ninguna de las dos es incorrecta; las dos hay que defenderlas.

La identidad del usuario no tiene una solución perfecta. No hay tabla que relacione las cuatro tarjetas. Cualquier estrategia que propongan será una aproximación, declaren sus supuestos y sus límites. En un proyecto real, esta es exactamente la conversación que tendría la Agencia.

**Empiecen por la matriz del bus, antes de escribir una sola tabla. Les va a ahorrar rehacer el modelo.**